LAPORAN AKHIR PROYEK TEKNOLOGI CERDAS

Prediksi Customer Churn Berbasis Business Intelligence, Machine Learning, dan LLM

Studi kasus e-commerce: dari data transaksi ke rekomendasi retensi berbasis bukti

Track: Reproduce (proyek referensi)

Artefak: `simulation/`

Tanggal: 21 September 2026

Penulis: diisi mahasiswa sebelum pengumpulan

Ringkasan Eksekutif

Proyek ini membangun alur analitik untuk retensi pelanggan e-commerce: data CSV divalidasi dan disiapkan, metrik Business Intelligence (BI) ditampilkan, *Random Forest* memprediksi kemungkinan churn, dan Large Language Model (LLM) lokal menyusun saran tindakan berdasarkan bukti yang dibatasi. Target adalah `churned` pada 8.000 pelanggan; evaluasi memakai test set terstratifikasi berukuran 1.600 pelanggan.

ROC-AUC	Recall churn	F1 churn	Churn test set
0,733	**0,483**	**0,387**	**8,94%**

Pada threshold 0,50, model mendeteksi 69 dari 143 pelanggan yang benar-benar churn, dengan 145 false positive. Accuracy 86,31% **tidak** melampaui baseline mayoritas 91,06%; accuracy saja menyesatkan pada kelas tidak seimbang. Nilai proyek terletak pada pemeringkatan risiko dan pengaturan threshold, bukan pada klaim bahwa seluruh churn dapat diprediksi tepat.

> **Temuan kualitas data.** `monthly_revenue.csv` merepresentasikan revenue order Delivered, sehingga `return_rate` selalu nol. Analisis return harus menggunakan `orders.csv`.

Daftar Isi

1. Pendahuluan
2. Data dan kualitas data
3. Metode dan arsitektur
4. Desain eksperimen
5. Hasil dan pembahasan
6. Aplikasi dan LLM
7. Etika, keterbatasan, dan kesimpulan

1. Pendahuluan

Masalah dan tujuan

Churn pelanggan mengurangi pendapatan berulang dan membuat upaya retensi terlambat bila hanya mengandalkan pengamatan manual. Proyek ini menyediakan aplikasi pembelajaran yang menautkan fakta transaksi, ringkasan BI, skor prediktif, dan narasi tindakan. Stakeholder utamanya adalah manajer retensi yang perlu memilih pelanggan untuk ditindaklanjuti serta alasan yang dapat diperiksa.

Pertanyaan rekayasa

- **RQ1:** Seberapa baik Random Forest membedakan pelanggan churn dan tidak churn?
- **RQ2:** Bagaimana threshold mengubah precision, recall, false positive, dan false negative?
- **RQ3:** Bagaimana LLM diberi evidence agar tidak mengarang fakta atau menganggap prediksi sebagai sebab?

Kontribusi

Kontribusi artefak ini adalah implementasi CSV → BI → ML → LLM → Streamlit untuk churn. Track laporan adalah **REPRODUCE**: pipeline, data, dan output diperiksa dari implementasi referensi yang tersedia; tidak ada klaim kebaruan algoritmik.

2. Data dan Kualitas Data

Item	Isi
Sumber	Dataset e-commerce bergaya Kaggle dalam `simulation/` ; provenance/lisensi sumber asli harus dilengkapi sebelum publikasi eksternal.
Snapshot	1 April 2026
Unit observasi ML	Satu baris per pelanggan pada `customers.csv`
Target	`churned` , klasifikasi biner
Tabel pendukung	Orders (transaksi), product summary (agregat produk), monthly revenue (agregat bulanan Delivered)

Pelanggan	Order	Produk	Revenue Delivered
8.000	**25.000**	**140**	**$2.585.126,50**

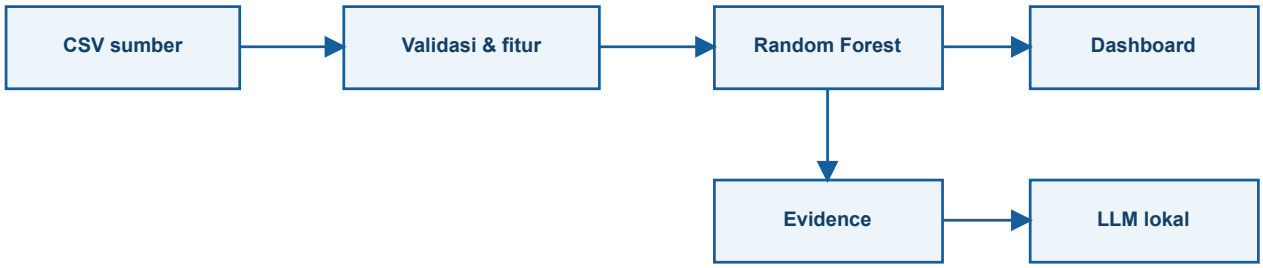
Pemeriksaan kualitas dan semantik

- Proporsi churn pelanggan 8,94%; kelas target minoritas.
- Return level order 8,08%.
- `customer_rating` hilang pada 63,00% order; digunakan sebagai evidence UI, bukan fitur model pelanggan.

- Total revenue product summary sesuai dengan order non-cancelled; total monthly revenue sesuai order Delivered.
- Agregat bulanan tidak valid untuk menyimpulkan return karena `return_rate` selalu nol.

> **Leakage.** Kategori tidak di-one-hot sebelum split. Imputasi dan encoding ditempatkan dalam *scikit-learn Pipeline*, sehingga parameter transformasi dipelajari dari data latih ketika model di-fit.

3. Metode dan Arsitektur



Gambar 1. Arsitektur end-to-end. LLM tidak menggantikan model klasifikasi.

Persiapan fitur

Data dibagi stratified menjadi 6.400 data latih dan 1.600 data uji (`test_size=0.20` , `random_state=42`). Tujuh fitur kategorikal meliputi negara, gender, tier keanggotaan, kategori/perangkat/metode pembayaran pilihan, serta channel akuisisi. Empat belas fitur numerik mencakup perilaku pembelian dan fitur rekayasa `customer_tenure_days` , `orders_per_year` , `reviews_per_order` , dan `returns_per_order` . Total fitur sebelum one-hot encoding adalah 21.

Model dan metrik

Pipeline memakai median imputation (numerik), most-frequent imputation dan OneHotEncoder (kategorikal), kemudian *RandomForestClassifier* dengan 350 pohon, `min_samples_leaf=3` , `class_weight=balanced` , dan seed 42. Metrik: precision, recall, F1, ROC-AUC, dan confusion matrix. Precision menilai alert yang benar, recall menilai churn terdeteksi, dan ROC-AUC menilai kemampuan peringkat lintas threshold.

4. Desain Eksperimen

Eksperimen	Konfigurasi	Tujuan	Hasil utama
E0	Baseline mayoritas: selalu “tidak churn”	Menguji makna accuracy model	Accuracy 0,911; recall churn 0
E1	Random Forest, threshold 0,50	Evaluasi konfigurasi tersimpan	F1 0,387; ROC-AUC 0,733
E2	Threshold 0,30 / 0,50 / 0,70	Trade-off kapasitas retensi	Recall turun saat threshold naik

```
python data_prep.py
python ml_model.py
streamlit run app.py
# LLM: ollama serve; ollama pull llama3.2
```

Evaluasi ini satu split hold-out, bukan cross-validation atau eksperimen kausal. Angka threshold dihitung ulang dari pipeline tersimpan dan `customer_test.csv` .

5. Hasil dan Pembahasan

Performa pada threshold 0,50

Metric	Nilai	Interpretasi singkat
Accuracy	0,863	Lebih rendah dari baseline mayoritas 0,911; jangan dipakai sendiri.
Precision churn	0,322	Sekitar 32 dari 100 alert adalah churn aktual.
Recall churn	0,483	69 dari 143 churn test terdeteksi.
F1 churn	0,387	Ringkasan keseimbangan precision–recall.
ROC-AUC	0,733	Kemampuan pemeringkatan moderat, di atas acak tetapi belum kuat.

Confusion matrix

	Pred. tidak churn	Pred. churn
Aktual tidak churn	1.312 (TN)	145 (FP)
Aktual churn	74 (FN)	69 (TP)

Fitur global terpenting

Fitur	Importance
days_since_last_purchase	0,147
total_orders	0,089
total_spend_usd	0,077
orders_per_year	0,072
customer_tenure_days	0,062

Feature importance adalah kontribusi relatif di dalam model, bukan sebab churn pada pelanggan individu.

Analisis threshold

Threshold	Precision	Recall	F1	FP	FN	TP
0,30	0,270	0,601	0,372	233	57	86
0,50	**0,322**	**0,483**	**0,387**	**145**	**74**	**69**
0,70	0,414	0,084	0,140	17	131	12

Threshold 0,30 cocok bila biaya kehilangan churn tinggi dan tim dapat menangani banyak alert, tetapi 233 pelanggan non-churn ikut ditarget. Threshold 0,70 mengurangi alert salah namun hanya menangkap 12 churn. Tanpa biaya kampanye, kapasitas tim, dan nilai pelanggan, tidak ada threshold tunggal yang paling benar.

5.2 Analisis Error

Jenis	ID	Bukti ringkas	Interpretasi yang diperbolehkan
False positive	C06173	204 hari sejak pembelian terakhir; Free; 8 order; probabilitas 0,644.	Inaktivitas tinggi memicu alert meski label aktual tidak churn. Alert adalah prioritas pemeriksaan, bukan keputusan otomatis.
False negative	C06465	7 hari sejak pembelian terakhir; Platinum; 9 order; probabilitas 0,196.	Perilaku yang terlihat aktif tidak menjamin tidak churn. Model melewatkan 74 churn pada threshold 0,50.
False negative	C05106	13 hari sejak pembelian terakhir; Gold; 2 order; probabilitas 0,410.	Sinyal fitur yang tersedia tidak cukup untuk seluruh mekanisme churn; penyebab tidak boleh diarang dari skor.

> Bukti error menunjukkan perlunya *human review*: fitur aktivitas dominan, sementara label churn mungkin dipengaruhi faktor yang tidak tersedia dalam data.

6. Aplikasi dan Integrasi LLM

Dashboard Streamlit memiliki empat tab: Kaggle Data untuk inspeksi tabel; BI untuk trend revenue dan kategori; Machine Learning untuk peluang churn dan threshold; dan LLM Analyst untuk rencana retensi. Pengguna memilih `customer_id`, lalu aplikasi membangun fitur dengan fungsi yang sama seperti pelatihan sebelum memanggil `predict_proba`.

Grounding dan batasan prompt

Prompt Ollama `llama3.2` memuat profil pelanggan, probabilitas churn, hingga lima order terbaru, dan delapan feature importance global. Instruksi mewajibkan LLM memakai fakta yang diberikan, menyatakan bahwa skor bukan sebab, tidak mengarang motif/keluhan/pendapatan, serta memberi dua observasi, dua aksi proporsional, dan satu peringatan batasan.

Aspek	Kontrol implementasi
Evidence	Profil mentah, order terbaru, skor ML, dan faktor global dikirim eksplisit.
Grounding	Instruksi “Use ONLY the supplied data”; evidence dapat dibuka pengguna di UI.
Runtime	Ollama lokal, model default `llama3.2`, temperature 0,2.
Klaim kausal	Dilarang; probabilitas dijelaskan sebagai prediksi.
Evaluasi LLM	Belum ada pengujian terstruktur sejumlah kasus; wajib sebelum deployment.

7. Etika, Keterbatasan, dan Kesimpulan

Penggunaan bertanggung jawab

- **Privasi:** customer ID dan atribut pelanggan harus dibatasi aksesnya.
- **Fairness:** country dan gender dapat membawa risiko disparitas; perlu evaluasi per kelompok.
- **Automation bias:** skor dan teks LLM harus mendukung, bukan menggantikan, keputusan staf.
- **LLM:** grounding mengurangi tetapi tidak menghilangkan risiko halusinasi; output harus diaudit terhadap prompt dan data sumber.
- **Keamanan:** prompt, log, model lokal, dan data retensi memerlukan pengendalian akses dan kebijakan penghapusan.

Keterbatasan

- Provenance dan lisensi sumber Kaggle tidak tercatat dalam artefak.
- Label historis bukan bukti mekanisme kausal; periode observasi perlu diperjelas.
- Hanya satu hold-out split; belum ada validasi silang, uji temporal, kalibrasi probabilitas, atau monitoring drift.
- Baseline mayoritas mengungguli model pada accuracy; performa churn masih moderat.
- Feature importance global tidak menjelaskan satu pelanggan secara kausal.
- LLM belum diuji kuantitatif untuk konsistensi evidence, keamanan, atau kegunaan pengguna nyata.

Kesimpulan

Pipeline berhasil menghubungkan data e-commerce, BI, prediksi churn, dan saran bahasa alami dalam satu dashboard. Pada 1.600 data uji, Random Forest mencapai ROC-AUC 0,733, precision churn 0,322, recall 0,483, dan F1 0,387 pada threshold 0,50. Threshold lebih rendah meningkatkan deteksi churn (recall 0,601 pada 0,30) dengan kenaikan false positive. LLM dirancang sebagai lapisan komunikasi berbasis evidence, bukan sumber fakta atau penyebab churn. Sebelum penggunaan nyata, proyek memerlukan dokumentasi data, evaluasi fairness/kalibrasi/temporal, dan evaluasi LLM terstruktur.

8. Reproduksibilitas dan Referensi

Artefak berada di `simulation/`. Dependensi tercantum di `simulation/requirements.txt`. Output yang diperiksa: `data_quality_report.json`, `model_metrics.json`, `feature_importance.csv`, `customer_predictions.csv`, dan `customer_churn_pipeline.pkl`. Seed split dan model adalah 42.

Breiman, L. (2001). Random forests. *Machine Learning, 45*, 5–32.

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Dokumentasi proyek: `simulation/README.md`, `data_prep.py`, `ml_model.py`, `vai_analyst.py`, dan `app.py`.

Lampiran: Pengungkapan Bantuan AI

Aktivitas	Tool/Model	Penggunaan dan verifikasi
Penyusunan laporan	Codex	Membantu struktur narasi; angka ditelusuri ke JSON/CSV dan dihitung ulang dari test set.

LLM aplikasi	Ollama / llama3.2	Rekomendasi retensi berbasis prompt; evidence dapat diperiksa pengguna.