Student Retention Dashboard

Business Intelligence, Machine Learning, dan dukungan analisis berbantuan LLM untuk mengeksplorasi status retensi mahasiswa.

Dataset
student_retention.csv

Isi laporan
Gambaran data - kualitas - dashboard - evaluasi model - batasan penggunaan

Disusun berdasarkan berkas aplikasi, data, dan hasil eksperimen yang tersedia di folder **student_doa**.

Tanggal laporan: 8 Oktober 2026

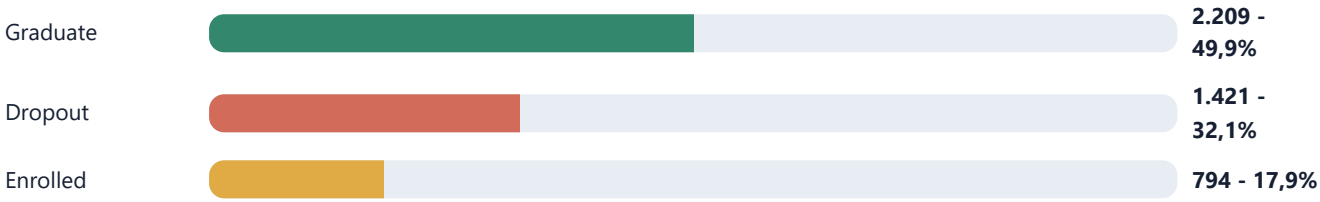
01 - RINGKASAN EKSEKUTIF

Tujuan dan hasil utama

Aplikasi ini menyatukan eksplorasi dataset mahasiswa, ringkasan historis, evaluasi model klasifikasi, simulasi prediksi untuk satu record, dan penyusunan prompt analisis berbahasa Indonesia. Dashboard dibuat dengan Streamlit; pipeline model menggunakan scikit-learn.

4.424	35	3	0
baris mahasiswa	kolom sumber	kelas target	sel kosong terlapor

Komposisi label pada data sumber



Hasil model yang tercatat: Accuracy 0,755; Macro F1 0,713; Weighted F1 0,761; dan ROC-AUC OVR berbobot 0,900 pada data uji.

Ruang lingkup aplikasi

- **Data Mahasiswa:** menampilkan tabel, filter target, komposisi kelas, dan pemeriksaan nilai kosong.
- **Business Intelligence:** memperlihatkan ringkasan status, nilai akademik, usia, pembayaran biaya kuliah, dan status utang.
- **Machine Learning:** evaluasi model Random Forest dan simulasi prediksi record terpilih.
- **LLM Analyst:** meninjau prompt dan, bila Ollama lokal tersedia, meminta analisis lanjutan.

Interpretasi: angka performa adalah hasil satu eksperimen dengan pemisahan data yang tercatat. Prediksi dan feature importance bersifat prediktif, bukan bukti penyebab atau keputusan otomatis atas mahasiswa.

02 - DATASET DAN KUALITAS DATA

Profil data mahasiswa

File utama `student_retention.csv` berisi 4.424 baris dan 35 kolom. Kolom sasaran yang digunakan adalah `Target`, dengan nilai *Dropout*, *Enrolled*, dan *Graduate*.

Kelompok variabel

Kelompok	Contoh informasi
Administrasi dan pendaftaran	Status perkawinan, mode dan urutan aplikasi, program studi, kehadiran siang/malam.
Latar belakang	Kualifikasi sebelumnya, kewarganegaraan, pendidikan dan pekerjaan orang tua.
Kondisi mahasiswa	Domisili, kebutuhan pendidikan khusus, status utang, pembayaran biaya kuliah, gender, beasiswa, usia, status internasional.
Aktivitas akademik	SKS semester 1 dan 2: dikreditkan, diambil, dievaluasi, lulus, nilai rata-rata, serta tanpa evaluasi.
Konteks ekonomi	Tingkat pengangguran, inflasi, dan GDP.
Label	`Target` : Dropout, Enrolled, atau Graduate.

Ringkasan kualitas dan pembagian

Kualitas yang tercatat

- Nilai kosong: 0
- Baris duplikat: 0
- Target tersedia dan memiliki tiga kelas

Pemisahan stratified

- Train: 3.318 baris (75%)
- Test: 1.106 baris (25%)
- Random state: 42

Catatan kategori: sejumlah kolom disimpan sebagai bilangan bulat berkode. Kolom seperti program studi, kualifikasi, dan pekerjaan orang tua diperlakukan sebagai kategori dalam pipeline, bukan skala numerik berurutan. Makna setiap kode perlu dirujuk ke kamus data.

Informasi kualitas di atas berasal dari data_quality_report.json yang tersedia. Laporan ini tidak melakukan audit independen atas asal-usul atau definisi tiap kode kategori.

Alur penggunaan dashboard

Dashboard menyajikan empat pilihan menu horizontal. Sidebar digunakan untuk memilih record mahasiswa dan ambang probabilitas dropout; konfigurasi itu dipakai konsisten pada halaman prediksi dan analisis LLM.

Data Mahasiswa

Pengguna dapat memfilter tabel berdasarkan target, melihat sampel data dan distribusi label, serta memeriksa ringkasan nilai kosong per kolom.

Business Intelligence

Halaman BI meringkas komposisi status dan menampilkan metrik historis agregat menurut target. Visual yang tersedia mencakup rata-rata nilai dan mata kuliah lulus per semester.

Indikator BI lain

- Median usia saat pendaftaran menurut status.
- Persentase pembayaran biaya kuliah terbarui menurut status.
- Ringkasan status utang menurut target.

Machine Learning

Menampilkan classification report, confusion matrix, metrik agregat, feature importance global, serta prediksi probabilistik untuk record terpilih.

Interpretasi yang tepat

> BI menggambarkan pola agregat di dataset historis. Perbedaan nilai atau status antar-kelompok tidak dengan sendirinya menjelaskan sebab terjadinya dropout atau kelulusan.

Label ID seperti `M00001` dibentuk dari urutan baris untuk keperluan pemilihan record di dashboard. ID tersebut bukan identitas resmi mahasiswa. Ambang dropout mengubah keputusan kelas simulasi berdasarkan probabilitas; ambang ini bukan kebijakan akademik.

Rangkaian file proyek

`app.py` (dashboard) - `data_prep.py` (validasi dan split) - `lihat_data.py` (inspeksi cepat) - `ml_model.py` (training/evaluasi) - `llm.py` (prompt dan Ollama).

Hasil pendukung mencakup laporan kualitas JSON, metrik model JSON, feature importance CSV, prediksi CSV, dan artefak pipeline model.

Metode dan evaluasi

Pipeline melatih classifier Random Forest untuk memprediksi tiga kelas target. Pemisahan train/test stratified 75/25 menggunakan random state 42. Kolom target dan ID baris dikeluarkan dari fitur.

Pra-pemrosesan

- Kolom kategori diproses dengan imputasi modus dan one-hot encoding.
- Kolom numerik diproses dengan imputasi median.
- Kategori yang belum dikenal ditangani dengan `handle_unknown="ignore"`.

Classifier

- 300 pohon keputusan.
- `class_weight="balanced"`.
- `min_samples_leaf=2`.
- Random state 42; pipeline scikit-learn.

Metrik data uji

Metrik	Nilai	Makna ringkas
Accuracy	0,755	Proporsi prediksi benar dari 1.106 baris uji.
Macro F1	0,713	Rata-rata F1 antar kelas dengan bobot sama.
Weighted F1	0,761	Rata-rata F1 dengan bobot jumlah sampel per kelas.
Weighted precision	0,772	Precision agregat berbobot.
Weighted recall	0,755	Recall agregat berbobot.
ROC-AUC OVR weighted	0,900	Pemisahan probabilistik one-vs-rest agregat berbobot.

Hasil per kelas

Kelas	Precision	Recall	F1	Sampel uji
Dropout	0,814	0,704	0,755	355
Enrolled	0,478	0,613	0,537	199
Graduate	0,851	0,839	0,845	552

Hal yang perlu diperhatikan: kinerja kelas Enrolled lebih rendah dibanding dua kelas lainnya. Ambang risiko dan hasil prediksi sebaiknya dievaluasi dengan kebutuhan kampus, biaya kesalahan, validasi temporal/eksternal, dan tinjauan manusia sebelum penggunaan operasional.

Interpretasi dan langkah lanjutan

Fitur penting global pada model

Fitur hasil transformasi	Importance
SKS lulus semester 2	0,1155
Nilai semester 2	0,0882
SKS lulus semester 1	0,0778
Nilai semester 1	0,0716
Evaluasi semester 2 dan semester 1	0,0498 dan 0,0462

Urutan di atas adalah feature importance global dari Random Forest. Ini menunjukkan kontribusi relatif terhadap pemisahan prediksi pada model, bukan efek kausal dan bukan alasan individual seorang mahasiswa memperoleh label tertentu.

LLM Analyst

Modul membentuk prompt dari sebagian profil akademik/administratif, kelas prediksi, probabilitas per kelas, dan faktor model global. Prompt meminta ringkasan yang membedakan fakta yang tersedia dari estimasi model, menyebut ketidakpastian, serta memberi saran tindak lanjut yang etis dan dapat diverifikasi.

Integrasi generasi jawaban menggunakan Ollama lokal dengan model bawaan `llama3.2`. Prompt tetap dapat dilihat tanpa koneksi. Untuk memperoleh jawaban, Ollama dan model tersebut harus tersedia pada perangkat yang menjalankan aplikasi.

Batasan penggunaan

- Dokumentasi folder tidak memberikan kamus lengkap untuk seluruh kode kategori atau penjelasan asal/proses pengumpulan data.
- Metrik yang dilaporkan berasal dari satu split acak; belum menunjukkan performa pada cohort baru atau institusi lain.
- Ketidakseimbangan jumlah kelas masih ada; skor agregat dapat menyamarkan kesalahan kelas Enrolled.
- Model tidak mengidentifikasi sebab dropout. Prediksi tidak boleh menjadi satu-satunya dasar keputusan penting.
- Data mahasiswa berpotensi sensitif; batasi akses dan hindari mengirim data identitas ke layanan eksternal.

> **Rekomendasi:** validasi definisi data dan fairness, tinjau false positive/false negative bersama pemangku kepentingan, uji pada data periode terpisah, lalu gunakan hasil hanya sebagai sinyal awal untuk dukungan manusiawi.

06 - PANDUAN MENJALANKAN APLIKASI

Menjalankan dan berkas proyek

Perintah berikut dijalankan dari terminal pada folder `student_doa`. Dependency tercantum dalam `requirements.txt`.

```
pip install -r requirements.txt
streamlit run app.py
```

Skrip pendukung

Berkas	Fungsi
`lihat_data.py`	Menampilkan ukuran, tipe kolom, nilai kosong, distribusi target, dan contoh baris.
`data_prep.py`	Memvalidasi target, menambahkan ID baris, membagi data secara stratified, dan menulis laporan kualitas.
`ml_model.py`	Melatih pipeline, menghitung metrik, lalu menyimpan pipeline, importance, dan prediksi.
`llm.py --prompt-only`	Menampilkan contoh prompt tanpa memanggil Ollama.

```
python lihat_data.py
python data_prep.py
python ml_model.py
python llm.py --prompt-only
```

Alur eksperimen CLI

1. Jalankan inspeksi data dan pastikan skema sesuai.
2. Jalankan persiapan data untuk menghasilkan split train/test.
3. Jalankan training/evaluasi; keluaran metrik dan artefak disimpan di folder proyek.
4. Jalankan dashboard Streamlit untuk eksplorasi interaktif.

Integrasi Ollama (opsional)

```
ollama serve
ollama pull llama3.2
```

Ollama berjalan sebagai layanan lokal. Model default dapat diubah melalui variabel lingkungan `OLLAMA_MODEL`.

Laporan ini disusun dari isi folder proyek pada 8 Oktober 2026. Hasil metrik, jumlah data, dan artefak mengikuti berkas yang tersedia pada saat penyusunan.

Apa isi file dataset di folder Student DOA?

File data sumber yang digunakan oleh aplikasi adalah `student_retention.csv`. Pada versi folder yang dilaporkan, tidak ada file bernama persis `dataset.csv`.

4.424	35	3
baris - satu record per mahasiswa	kolom - fitur dan satu target	label: Dropout, Enrolled, Graduate

Informasi yang dicatat

Kolom-kolomnya memuat beberapa kelompok informasi berikut:

- **Pendaftaran dan program:** status perkawinan, mode dan urutan aplikasi, program studi, kehadiran siang/malam, kualifikasi sebelumnya.
- **Latar belakang:** kewarganegaraan, pendidikan dan pekerjaan ayah/ibu.
- **Kondisi mahasiswa:** domisili, kebutuhan pendidikan khusus, status utang dan pembayaran biaya kuliah, gender, beasiswa, usia masuk, status internasional.
- **Akademik semester 1 dan 2:** SKS dikreditkan/diambil/dievaluasi/lulus, nilai, dan jumlah tanpa evaluasi.
- **Kondisi ekonomi:** tingkat pengangguran, inflasi, dan GDP.
- **Target:** status hasil studi yang akan dieksplorasi atau diprediksi.

> **Penting:** banyak nilai bilangan bulat merupakan kode kategori, bukan ukuran. Contohnya kode program studi atau kualifikasi tidak berarti program bernomor lebih tinggi memiliki tingkat yang lebih tinggi. Perlu kamus data untuk menafsirkan arti setiap kode.

Cara melihat isi data

1. **Di dashboard:** jalankan aplikasi, buka menu *Data Mahasiswa*, lalu gunakan filter status untuk membatasi tabel. Dashboard memperlihatkan hingga 500 baris pertama dari hasil filter.
2. **Ringkasan di terminal:** dari folder `student_doa`, jalankan skrip inspeksi berikut. Skrip menampilkan ukuran, tipe kolom, nilai kosong, distribusi target, dan lima baris contoh.

```
cd student_doa
python lihat_data.py
```

Untuk menjalankan dashboard secara interaktif:

```
cd student_doa
streamlit run app.py
```

File sumber dan file hasil olahan

`student_retention.csv` adalah sumber data mentah yang dibaca dashboard.

`student_ml_dataset.csv` adalah hasil persiapan untuk ML (termasuk ID baris teknis); `student_train.csv` dan `student_test.csv` merupakan pembagian train/test. File-file tersebut bukan dataset sumber yang berbeda.